

SLM / Edge Device arXiv Daily Summary

생성일: 2026-05-24 05:28 KST

Gemini 모델: gemini-2.5-flash

검색 범위: 최근 7일

[논문] 논문 1

1. 제목: FTerViT: Fully Ternary Vision Transformer

2. 저자: Szymon Ruciski, Pietro Bonazzi, Engin Türetken, Simon Narduzzi, Michele Magno, Nadim Maamari

3. 카테고리: SLM/Edge/On-device

4. 관련성 판단: 이 논문은 Vision Transformer에 대한 것이지만, 마이크로컨트롤러와 같은 극도로 자원 제약적인 엣지 디바이스에 모델을 배포하기 위한 극단적인 양자화(삼진화), 압축, 메모리 효율성 기술을 다룹니다. 이는 SLM을 엣지 디바이스에 경량화하여 배포하는 데 필요한 핵심 기술과 직접적으로 관련됩니다. 특히, 모든 가중치와 정규화 파라미터를 삼진화하여 메모리 사용량을 획기적으로 줄이고 실제 MCU에 구현한 점이 중요합니다.

5. 초록 요약: 기존 삼진화 Vision Transformer는 인코더 레이어만 삼진화하여 패치 임베딩, LayerNorm 등은 고정밀도로 남겨두어 마이크로컨트롤러와 같은 자원 제약적인 프로세서에서의 배포 효율성을 저해했습니다. 이 논문은 모든 가중치 행렬과 정규화 파라미터를 삼진화하는 완전 삼진화 Vision Transformer (FTerViT)를 제안합니다. 이를 위해 TernaryBitConv2d와 TernaryLayerNorm이라는 새로운 연산자를 도입하고, 지식 증류 및 경량 양자화 인식 복구 단계를 통해 모델을 훈련합니다.

6. 서론/앞부분 기반 판단: Vision Transformer는 강력한 이미지 분류기이지만, 방대한 메모리 사용량 때문에 마이크로컨트롤러급 디바이스에는 부적합합니다. 예를 들어, DeiT-Small은 FP32에서 88.3MB를 요구하지만, 일반적인 MCU는 몇 MB의 외부 RAM만 제공합니다. 삼진 양자화는 가중치를 $\{-1, 0, +1\}$ 로 제한하고 2비트로 패킹하여 이론적으로 FP32 모델 대비 16배의 가중치 압축을 달성할 수 있습니다. 기존 저비트 ViT는 인코더 레이어만 삼진화하여 패치 임베딩, LayerNorm, 분류기 헤드를 INT8 또는 FP32로 남겨두는데, 이는 2비트에서는 지배적인 병목이 됩니다. 본 연구는 이러한 비삼진화 구성 요소가 전체 모델 크기의 상당 부분을 차지하는 문제를 해결하기 위해 모든 구성 요소를 삼진화하는 것을 목표로 합니다.

7. 핵심 기여사항:

- * Vision Transformer의 가장 취약한 구성 요소인 패치 임베딩, LayerNorm, 분류기 헤드를 $\{-1, 0, +1\}$ 로 삼진화할 수 있음을 최초로 입증했습니다.
- * 극단적인 압축에서도 높은 정확도를 유지합니다 (ImageNet-1K에서 6.09MB로 82.43% top-1, 14.6배 압축).
- * 동일 아키텍처 지식 증류 및 경량 복구 미세 조정을 기반으로 하는 간단하고 효과적인 훈련 전략을 제안합니다.
- * 듀얼 코어 ESP32-S3와 같은 자원 제약적인 MCU 플랫폼에 삼진화 Vision Transformer의 독립형 C 구현을 시연하여 실제 배포 가능성을 검증했습니다.

8. 실험 결과: W2A8 DeiT-III-S 모델이 384x384 해상도에서 6.09MB 크기로 ImageNet-1K top-1 정확도 82.43%를 달성하여 FP32 대비 2.42%p 감소했으며, 이전 삼진화 ViT 방법보다 최대 8%p 우수합니다. FTerViT-Small (DeiT-III-Small 기반, 224x224 해상도, 5.81MB)은 79.64% ImageNet-1K top-1 정확도를 달성하며, 8MB PSRAM을 가진 \$10 ESP32-S3에서 실행 가능함을 보여주었습니다.

9. 내 연구와의 관련성: SLM을 엣지 디바이스에 배포할 때 발생하는 메모리 및 연산 제약 문제를 해결하기 위한 극단적인 양자화 및 압축 기법에 대한 통찰을 제공합니다. 특히, 모델의 모든 구성 요소를 양자화하는 방법론과 실제

마이크로컨트롤러에서의 구현 및 성능 검증은 SLM의 TinyML 배포 전략 수립에 중요한 참고 자료가 될 수 있습니다.

10. 확인해야 할 부분: 삼진화가 SLM 아키텍처에 어떻게 적용될 수 있는지, 그리고 언어 모델의 특성상 삼진화가 정확도에 미치는 영향은 어떠한지 추가적인 연구가 필요합니다. 또한, 제안된 TernaryBitConv2d 및 TernaryLayerNorm 연산자가 SLM의 특정 레이어에 어떻게 매핑될 수 있는지 확인해야 합니다.

11. arXiv PDF: <https://arxiv.org/pdf/2605.21171.pdf>

[논문] 논문 2

1. 제목: E-ReCON: An Energy- and Resource-Efficient Precision-Configurable Sparse nvCIM Macro for Conventional and Spiking Neural Edge Inference

2. 저자: Ankit Kumar Tenwar, Mukul Lokhande, Santosh Kumar Vishvakarma

3. 카테고리: SLM/Edge/On-device

4. 관련성 판단: 이 논문은 엣지 AI 추론을 위한 에너지 및 자원 효율적인 컴퓨트-인-메모리(CIM) 하드웨어 매크로를 제안합니다. SLM 모델 자체에 대한 내용은 아니지만, SLM을 엣지 디바이스에 배포할 때 필수적인 하드웨어 가속 및 최적화 기술, 특히 메모리 효율성, 낮은 지연 시간, 전력 효율성, 그리고 희소성(pruning)을 통한 압축을 다루므로 매우 관련성이 높습니다.

5. 초록 요약: 엣지 AI 추론을 위한 16Kb 에너지 및 자원 효율적인 디지털 컴퓨트-인-메모리(DCIM) 매크로인 E-ReCON을 제안합니다. 이 매크로는 콤팩트한 3T1R ReRAM 비트셀을 기반으로 하며, CNN 및 SNN 워크로드 모두에서 AND 기반 인-메모리 곱셈을 지원합니다. 새로운 인터리브드 덧셈기 트리를 도입하여 트랜지스터 수와 전력 소비를 줄이고, 65nm CMOS에서 0.48ns의 최소 지연 시간과 최대 419 TOPS/W의 에너지 효율을 달성합니다. 40% 가지치기(pruning)를 통해 원래 정확도의 99.8%를 유지하면서 MAC 연산 및 계산 사이클을 줄일 수 있음을 보여줍니다.

6. 서론/앞부분 기반 판단: 이미지 분류, 음성 인식, 생체 의학 센싱 등 엣지 디바이스에 AI 워크로드가 증가하고 있지만, 기존 폰 노이만 아키텍처는 메모리와 처리 장치 간의 빈번한 데이터 이동으로 인해 상당한 지연 시간과 에너지 오버헤드를 겪습니다. 컴퓨트-인-메모리(CIM) 아키텍처는 메모리 어레이 내에서 직접 연산을 수행하여 데이터 전송을 줄이고 처리량 및 에너지 효율을 향상시키는 유망한 대안으로 부상했습니다. ReRAM은 낮은 동작 전압, 빠른 스위칭 속도, 콤팩트한 풋프린트, CMOS 호환성, 비휘발성 특성으로 인해 CIM 시스템에 특히 매력적입니다. 이 논문은 아날로그 CIM의 정밀도 및 노이즈 한계를 극복하는 ADC-less 디지털 ReRAM 기반 CIM 매크로를 제안하며, SNN 추론에도 적합합니다.

7. 핵심 기여사항:

- * 엣지 AI 추론을 위한 에너지 및 자원 효율적인 16Kb 디지털 컴퓨트-인-메모리(DCIM) 매크로인 E-ReCON을 제안합니다.
- * 콤팩트한 3T1R ReRAM 비트셀과 새로운 인터리브드 덧셈기 트리를 통해 트랜지스터 수와 전력 소비를 크게 줄였습니다.
- * 40% 가지치기(pruning)를 적용하여 높은 정확도를 유지하면서 연산량을 줄이는 방법을 시연했습니다.
- * 기존 ADC 기반 ReRAM-CIM 설계 대비 지연 시간과 에너지 효율을 30-40% 향상시키면서 견고한 작동을 유지합니다.

8. 실험 결과: 65nm CMOS에서 1.2V로 구현된 제안된 매크로는 0.48ns의 최소 지연 시간, 2.31-3.1 TOPS의 처리량, 최대 419 TOPS/W의 에너지 효율을 달성합니다. LeNet-5, AlexNet, CNN-8 모델에서 MNIST/A-Z, CIFAR10, SVHN 데이터셋에 대해 각각 97.81%, 93.23%, 96.51%의 정확도를 달성했습니다. 40% 가지치기는 원래 정확도의 거의 99.8%를 유지하면서 MAC 연산 및 계산 사이클을 줄였습니다. SNN 워크로드의 경우, VGG-8, VGG-16, ResNet-18 네트워크에서 FP32 기준에 가까운 정확도를 달성했습니다.

9. 내 연구와의 관련성: SLM을 엣지 디바이스에 배포할 때 하드웨어 수준에서 메모리, 지연 시간, 전력 효율성을 최적화하는 방법에 대한 깊은 이해를 제공합니다. 특히, 컴퓨트-인-메모리 아키텍처, 희소성(pruning) 적용, 그리고 ReRAM과 같은 비휘발성 메모리 기술의 활용은 SLM의 엣지 배포를 위한 맞춤형 하드웨어 설계 또는 최적화 전략을 고려할 때 중요한 참고

자료가 될 수 있습니다.

10. 확인해야 할 부분: 제안된 CIM 매크로가 SLM의 복잡한 연산(예: 어텐션 메커니즘)에 어떻게 효율적으로 적용될 수 있는지, 그리고 SLM의 특정 아키텍처(예: 트랜스포머)에 최적화된 CIM 설계는 어떠한지 추가적인 분석이 필요합니다.

11. arXiv PDF: <https://arxiv.org/pdf/2605.20717.pdf>

[논문] 논문 3

1. 제목: AIGaitor: Privacy-preserving and cloud-free motion analysis for everyone, using edge computing

2. 저자: Lauhitya Reddy, Trisha M. Kesar, Hyeokhyen Kwon

3. 카테고리: SLM/Edge/On-device

4. 관련성 판단: 이 논문은 스마트폰과 같은 엣지 디바이스에서 클라우드 없이 딥러닝 기반의 복잡한 모션 분석을 수행하는 시스템을 다룹니다. "경량 모델" 및 "온디바이스 신경망 가속기"를 활용하여 지연 시간을 최적화하고 실제 배포 가능성을 입증한 점이 SLM의 엣지 배포 및 경량화 전략과 밀접하게 관련됩니다. 특히, 시스템 구성 요소 중 "vision-language model"을 언급하여 SLM과의 직접적인 연결점도 있습니다.

5. 초록 요약: AIGaitor는 개인 정보 보호를 준수하고 클라우드 없이 작동하는 모션 분석 시스템으로, 마커리스 단안 모션 캡처 파이프라인과 다운스트림 딥러닝 분석을 소비자 스마트폰의 온디바이스 신경망 가속기를 사용하여 전적으로 수행합니다. 이 시스템은 모바일 iOS 구현을 최적화하고 벤치마킹하여, 10초 분량의 4K 60fps 비디오 클립을 iPhone 14에서 77초 만에 처리하며, 네트워크 전송을 포함할 경우 고성능 클라우드 서버와 유사하거나 더 빠른 성능을 보입니다. 경량 모델과 효율적인 처리로 저비용, 개인 정보 보호, 접근성을 갖춘 임상 적용 가능한 움직임 분석을 제공합니다.

6. 서론/앞부분 기반 판단: 제공된 정보 기준으로는 서론/앞부분 텍스트가 명확히 추출되지 않았으므로 초록을 중심으로 판단합니다. 모션 캡처는 인간 움직임 측정의 표준이지만, 비용, 기술적 복잡성, 개인 정보 보호 문제로 인해 임상 사용이 제한적입니다. AIGaitor는 이러한 장벽을 해결하기 위해 스마트폰에서 완전히 온디바이스로 작동하는 시스템을 설계했습니다. 이는 클라우드 오프로딩 없이 로컬에서 모든 처리를 수행하여 개인 정보 보호를 강화하고 접근성을 높이는 것을 목표로 합니다. 시스템은 2D 및 3D 자세 추정, 자세 최적화, 골격 기반 딥러닝 분석, 그리고 비전-언어 모델을 포함한 모바일 iOS 파이프라인 구성 요소를 최적화하고 벤치마킹했습니다.

7. 핵심 기여사항:

- * 개인 정보 보호를 준수하고 클라우드 없이 소비자 스마트폰에서 완전히 온디바이스로 작동하는 모션 분석 시스템 AIGaitor를 개발했습니다.
- * 온디바이스 신경망 가속기를 활용하여 마커리스 단안 모션 캡처 및 딥러닝 분석 파이프라인을 효율적으로 실행합니다.
- * 경량 모델(예: ViTPose-s)을 통해 실시간 키포인트 추출 및 서브-밀리초 단위의 보행 분류를 달성했습니다.
- * 최초로 엔드-투-엔드 온디바이스 모션 캡처 및 다운스트림 딥러닝 분석을 시연하여, 저비용, 개인 정보 보호, 접근성을 갖춘 임상 적용 가능한 움직임 분석을 가능하게 했습니다.

8. 실험 결과: Time-Priority 엔드-투-엔드 온디바이스 파이프라인은 iPhone 14에서 10초 분량의 4K 60fps 비디오 클립을 77초 만에 처리하며, 이는 네트워크 전송을 포함할 경우 고성능 NVIDIA H200 클라우드 서버와 유사하거나 더 빠른 성능입니다. 경량 모델인 ViTPose-s는 실시간 키포인트 추출을 달성하고, 골격 기반 액션 인식 모델은 동일 클립에서 서브-밀리초 단위의 보행 분류 정확도를 제공합니다.

9. 내 연구와의 관련성: SLM을 포함한 복잡한 AI 모델을 스마트폰과 같은 모바일 엣지 디바이스에 성공적으로 배포하기 위한 실제적인 접근 방식과 성능 최적화 사례를 보여줍니다. 특히, 온디바이스 신경망 가속기 활용, 경량 모델 설계, 그리고 클라우드 의존성 제거를 통한 지연 시간 및 개인 정보 보호 개선은 SLM의 엣지 배포 전략 수립에 중요한 시사점을 제공합니다. 시스템에 비전-언어 모델이 포함되어 있다는 점도 SLM과의 직접적인 연관성을 높입니다.

10. 확인해야 할 부분: AIGaitor 시스템 내에서 "vision-language model"이 구체적으로 어떤 역할을 하며, 이 모델의 경량화 및 온디바이스 최적화에 어떤 기법이 적용되었는지 상세히 살펴볼 필요가 있습니다. 또한, 모션 분석 외에 일반적인 SLM 작업에 대한 온디바이스 성능 및 효율성 확장 가능성을 평가해야 합니다.

11. arXiv PDF: <https://arxiv.org/pdf/2605.21421.pdf>