

SLM / Edge Device arXiv Daily Summary

생성일: 2026-07-02 07:26 KST

Gemini 모델: gemini-2.5-flash

검색 범위: 최근 30일

[논문] 논문 1

1. 제목: Decomposing Memorization Reduction in Privacy-Preserving Fine-Tuning of SLMs for CSIRTs

2. 저자: Cristhian Kapelinski, Diego Kreutz

3. 카테고리: SLM/Edge/On-device

4. 관련성 판단: 이 논문은 1B~3B 파라미터의 소형 언어 모델(SLM)을 사용하여 엣지 환경(CSIRT의 온프레미스 하드웨어 제약)에서 LoRA 및 QLoRA와 같은 PEFT 기법을 통해 구조화된 데이터를 미세 조정하는 방법을 다룹니다. 특히 개인 정보 보호와 메모리 절감에 초점을 맞추고 있어, SLM의 엣지 배포 및 효율적인 학습에 매우 관련성이 높습니다.

5. 초록 요약: CSIRT(컴퓨터 보안 사고 대응팀)는 취약점 스캔 기록을 사용하여 언어 모델을 미세 조정하지만, 이는 내부 네트워크 토폴로지를 노출하여 개인 정보 보호 위험을 초래합니다. 본 연구는 1B~3B SLM을 구조화된 CSIRT 데이터에 LoRA 어댑터를 사용하여 미세 조정할 때, DP-SGD 및 HMAC 가명화가 메모리 감소에 어떻게 영향을 미치는지 실증적으로 조사합니다. 연구 결과, 최적화 업데이트 횟수 감소가 메모리 감소의 주요 원인이며, HMAC 가명화는 원래 식별자 노출을 줄이지만, 평가된 학습 예산 내에서는 1B~3B SLM이 실용적인 성능을 달성하지 못함을 보여줍니다.

6. 서론/앞부분 기반 판단: CSIRT는 증가하는 사고 대응 규모에 맞춰 언어 모델을 활용하여 분류 및 지침을 자동화하려 하지만, 운영 기록을 미세 조정하는 과정에서 내부 토폴로지를 노출하는 식별자가 포함되어 GDPR/LGPD와 같은 규제와 충돌하는 문제의식을 제기합니다. 기존 연구들은 대규모 모델이나 일반 벤치마크에 집중했거나, PEFT와 DP-SGD의 복합적인 상호작용을 다루지 않았습니다. 이 논문은 1B~3B SLM이 온프레미스 하드웨어 제약에 적합하다는 점에 주목하여, 구조화된 CSIRT 데이터에 대한 개인 정보 보호 미세 조정에서 메모리 및 유틸리티를 평가하는 최초의 실증 연구를 수행합니다.

7. 핵심 기여사항:

- * 1B~3B SLM에 대한 개인 정보 보호 미세 조정에서 메모리 및 분류 유틸리티에 대한 최초의 실증 연구.
- * LoRA 어댑터를 활용한 4가지 학습 방식(raw, QLoRA, DP-SGD)에 걸쳐 96개 어댑터를 평가.
- * 최적화 업데이트 횟수 감소가 메모리 감소에 미치는 영향을 정량화하고, DP-SGD의 추가적인 메모리 감소 효과가 제한적임을 밝힘.
- * HMAC 가명화가 원래 식별자 노출을 줄이는 효과를 입증하고, 가명화된 식별자가 새로운 메모리 대상이 되지 않음을 확인.
- * 평가된 학습 예산 내에서 1B~3B SLM의 운영 성능 한계를 제시.

8. 실험 결과: 96개 LoRA 어댑터에 걸쳐 F1 점수가 0.19에서 0.28 사이에 머물러, 평가된 학습 예산 내에서는 1B~3B SLM이 운영상 유용한 성능을 달성하지 못함을 보여줍니다. 최적화 업데이트 횟수 감소가 메모리 감소의 66%~132%를 설명하며, DP-SGD는 추가적인 측정 가능한 메모리 감소를 제공하지 않습니다. HMAC 가명화는 노출을 40%~61% 감소시킵니다.

9. 내 연구와의 관련성: SLM을 엣지 디바이스에 배포하고 LoRA/QLoRA를 사용하여 미세 조정할 때, 구조화된 데이터 처리 및 개인 정보 보호 측면에서 고려해야 할 사항과 성능 한계를 이해하는 데 도움이 됩니다. 특히, 특정 도메인의 구조화된 데이터에 대한 SLM의 성능과 PEFT 기법의 효과를 평가하는 데 참고할 수 있습니다.

10. 확인해야 할 부분:

- * SLM이 구조화된 CSIRT 데이터를 처리할 때 어떤 종류의 "출력 형식"을 생성하는지 (예: 분류 레이블, 요약, 특정 구조의

응답 등).

- * 개인 정보 보호 기법이 출력 형식 준수에 미치는 영향.
- * 성능이 낮게 나온 원인 분석 및 개선 방안 (예: 더 많은 학습 데이터, 다른 PEFT 기법, 모델 아키텍처 등).

11. arXiv PDF: <https://arxiv.org/pdf/2606.28479.pdf>

[논문] 논문 2

1. 제목: Clinically Structured Rank-Gated LoRA for Cross-Benchmark Medical Question Answering

2. 저자: Yining Huang

3. 카테고리: Format-LoRA/Structured Output

4. 관련성 판단: 이 논문은 Qwen3-8B 모델을 기반으로 LoRA의 랭크 차원을 입력 조건부로 제어하는 새로운 PEFT 방법인 BiRG-LoRA를 제안합니다. 특히 의료 QA와 같이 이질적인 지식 도메인과 추론 작업에 대해 "임상적으로 구조화된 랭크 할당"을 통해 어댑터의 효율성과 성능을 높이는 데 중점을 둡니다. 이는 PEFT를 사용하여 모델의 내부 동작을 구조화하고 특정 출력 형식(여기서는 다중 선택 답변)에 더 잘 맞추는 접근 방식과 관련성이 높습니다.

5. 초록 요약: 의료 다중 선택 질문 답변은 이질적인 지식 도메인과 추론 작업에 걸쳐 매개변수 효율적인 적응을 요구합니다. 본 논문은 의료 QA를 위한 단일 어댑터 랭크 게이팅 LoRA 방법인 BiRG-LoRA를 제안합니다. BiRG-LoRA는 각 질문에 대해 숨겨진 의미론적 증거와 전문 분야/직업 사전 지식, 임상 작업 사전 지식 및 그 상호 작용을 결합하여 랭크 원자의 최소한 부분 집합을 선택하는 이층 게이트를 통해 랭크 차원을 입력 조건부로 만듭니다. Qwen3-8B 프로토콜에서 BiRG-LoRA는 MoELoRA보다 0.89%p 높은 69.31%의 매크로 평균 정확도를 달성하며, 28.1% 더 적은 학습 가능한 매개변수를 사용합니다.

6. 서론/앞부분 기반 판단: 의료 LLM은 CMB, CMExam 등 다양한 시험 스타일의 다중 선택 벤치마크로 평가되지만, 이 벤치마크들은 이질적인 의료 전문 분야, 직업 역할, 추론 작업을 혼합하고 있어 일반적인 PEFT 방법으로는 적응이 어렵다는 문제의식을 제기합니다. 단일 고정 LoRA 업데이트는 특정 부분 집합을 개선하는 동시에 다른 부분을 악화시킬 수 있습니다. 저자는 순수하게 일반적인 랭크별 전문가 관점이 의학 분야에서 라우팅 신호가 임의의 작업 ID가 아니라 의미 있는 구조를 가진다는 점을 놓친다고 지적하며, 임상적으로 의미 있는 축을 사용하여 단일 LoRA 어댑터가 내부 랭크 채널을 할당할 수 있는지 질문합니다. 이에 BiRG-LoRA를 제안하여 임상 구조를 어댑터 자체의 일부로 만듭니다.

7. 핵심 기여사항:

- * 의료 QA를 위한 이층 랭크 게이팅 LoRA(BiRG-LoRA)를 도입하여, 전문 분야/직업 및 임상 작업 사전 지식이 단일 어댑터 내에서 최소 랭크 활성화를 공동으로 안내하도록 함.
- * 선택된 어댑터 업데이트의 강도를 제어하는 입력 조건부 주입 계수를 추가.
- * Qwen3-8B 기반으로 바닐라 LoRA, MoELoRA 등 다양한 PEFT 기준선과 비교하여 우수한 성능과 매개변수 효율성을 입증.
- * 쌍별, 벤치마크 계층화된 부트스트랩 테스트를 통해 주요 매크로 평균 이득이 평가 세트 샘플링 노이즈로 설명될 가능성이 낮음을 보여줌.

8. 실험 결과: Qwen3-8B 모델을 사용하여 4개 벤치마크(CMB, CMExam, MedQA, MedMCQA)에서 평균 69.31%의 매크로 평균 정확도를 달성했습니다. 이는 MoELoRA보다 0.89%p 높고, 학습 가능한 매개변수는 28.1% 적습니다 (BiRG-LoRA 66.59M vs MoELoRA 92.60M). 바닐라 LoRA r16 및 활성 랭크 매칭 LoRA r4보다 0.83 매크로 포인트 향상되었습니다.

9. 내 연구와의 관련성: 특정 도메인(의료)에서 SLM에 가까운 모델(Qwen3-8B)을 PEFT(LoRA)로 미세 조정하여, 입력의 구조적 특성(질문 유형)에 따라 어댑터의 동작을 동적으로 조절하는 방식은, 내 연구에서 다양한 출력 형식(JSON, 함수 호출 등)을 생성하기 위해 모델의 내부 동작을 구조화하고 제어하는 데 영감을 줄 수 있습니다. 특히, "structured output"을 직접

생성하는 것은 아니지만, "clinically structured rank allocation"을 통해 모델의 적응 방식을 구조화하는 아이디어가 유용합니다.

10. 확인해야 할 부분:

- * 랭크 게이팅 메커니즘이 일반적인 구조화된 출력 형식(JSON, 스키마) 생성 작업에 어떻게 적용될 수 있는지.
- * "입력 조건부 주입 계수"가 출력 형식의 강도나 신뢰도를 제어하는 데 활용될 수 있는지.
- * 8B 모델이 아닌 더 작은 SLM(예: 1B~3B)에서도 유사한 랭크 게이팅 전략이 효과적인지.

11. arXiv PDF: <https://arxiv.org/pdf/2606.31432.pdf>

[논문] 논문 3

1. 제목: Learning to Select, Not Relearn: Hard-Routed Mixtures of Reasoning LoRAs

2. 저자: Seyed Alireza Molavi, Zhan Su, Yan Hu, Peyman Sheikholharam Mashhadi, Stefan Byttner, Prayag Tiwari

3. 카테고리: Format-LoRA/Structured Output

4. 관련성 판단: 이 논문은 독립적으로 학습된 LoRA 어댑터들을 단일 모델로 구성하는 새로운 PEFT 프레임워크인 Hard-Routed MoR-LoRA를 제안합니다. 특히, "추론 LoRA 전문가"를 활용하고 "하드 라우팅"을 통해 토큰별로 하나의 전문가를 선택하는 방식은, 모델이 특정 추론 경로를 따르거나 구조화된 응답을 생성할 때 필요한 내부 제어 메커니즘과 관련성이 높습니다. "Format-LoRA/Structured Output" 카테고리도 직접적인 관련성을 시사합니다.

5. 초록 요약: 독립적으로 학습된 LoRA 어댑터를 단일 대규모 언어 모델로 구성하는 것은 다중 도메인 적응에 유용하지만, 기존 MoE 방식은 스케일 불일치를 야기할 수 있습니다. 본 논문은 검증 가능한 피드백을 통한 강화 학습으로 추론 LoRA 전문가를 독립적으로 학습시킨 후, 이들을 고정하고 경량 라우터와 작은 어텐션 LoRA만을 학습시켜 통합하는 Hard-Routed MoR-LoRA 프레임워크를 제안합니다. 라우터는 하드 top-1 라우팅을 사용하여 토큰당 하나의 전문가를 선택하며, 이는 기존 소프트 라우팅 방식보다 적은 학습 가능한 매개변수로 전문가 동작을 보존합니다.

6. 서론/앞부분 기반 판단: LLM의 전문 도메인 적응은 전체 미세 조정 시 막대한 계산 비용과 학습 데이터 접근성 문제를 야기하며, PEFT 방법이 이를 해결합니다. 특히 LoRA는 경량의 학습 가능한 행렬을 추가하여 널리 사용됩니다. 그러나 독립적으로 학습된 LoRA 어댑터를 MoE 방식으로 구성할 때, 소프트 라우팅은 각 LoRA 모듈이 원래 학습된 단위 스케일의 가산 업데이트를 변경할 수 있다는 문제의식을 제기합니다. 또한, 기존 LoRA 구성 방법은 주로 지도 학습 기반 다중 작업 미세 조정에 초점을 맞추고, CoT(Chain-of-Thought) 추론 능력을 가진 명령어 튜닝 모델의 전문가 학습 및 통합은 다루지 않았습니다. 이에 본 연구는 추론 획득과 전문가 선택을 분리하는 Hard-Routed MoR-LoRA를 제안합니다.

7. 핵심 기여사항:

- * 독립적으로 학습된 고정 LoRA 어댑터에 소프트 MoE 라우팅을 적용할 때 발생하는 스케일 불일치 문제를 식별하고, 단위 스케일 하드 라우팅을 통해 이를 해결.
- * 검증 가능한 피드백을 통한 강화 학습(RLVF)으로 추론 LoRA 전문가를 학습시키고, 경량 라우터와 작은 어텐션 LoRA만을 학습시켜 통합하는 2단계 프레임워크 제안.
- * 하드 라우팅이 소프트 라우팅 기준선보다 적은 학습 가능한 매개변수로 전문가 동작을 보존하면서 유사하거나 더 나은 성능을 달성함을 입증.
- * 정규화된 소프트 혼합이 암묵적으로 거의 하드 top-1 선택처럼 동작함을 분석하여 하드 라우팅의 타당성을 뒷받침.

8. 실험 결과: 5개 벤치마크와 여러 모델 스케일에서 실험한 결과, Hard-Routed MoR-LoRA는 소프트 라우팅 기준선보다 적은 학습 가능한 매개변수를 사용하면서 전문가 동작을 보존하고 유사하거나 더 나은 성능을 달성했습니다. RLVF가 유능한 모델에 대해 더 강력한 추론 전문가를 생성함을 보여주었습니다.

9. 내 연구와의 관련성: LoRA 어댑터를 활용하여 모델의 특정 추론 능력이나 출력 형식을 제어하는 데 있어, 여러 전문가를

효율적으로 구성하고 선택하는 방법에 대한 깊은 통찰을 제공합니다. 특히, "하드 라우팅"을 통해 특정 출력 형식(예: JSON 스키마 준수, 함수 호출)에 필요한 특정 전문가를 명확하게 활성화하는 아이디어를 탐색하는 데 유용할 수 있습니다.

10. 확인해야 할 부분:

- * 이 프레임워크가 명시적인 JSON/스키마 출력, 함수 호출과 같은 특정 구조화된 출력 형식 생성에 어떻게 적용될 수 있는지.
- * "추론 LoRA 전문가"가 특정 출력 형식 준수와 관련된 지식을 어떻게 인코딩하는지.
- * SLM(예: 1B~3B)에서도 이 하드 라우팅 방식이 효율적으로 작동하는지.

11. arXiv PDF: <https://arxiv.org/pdf/2606.31413.pdf>