

# SLM / Edge Device arXiv Daily Summary

생성일: 2026-07-26 05:29 KST

Gemini 모델: gemini-2.5-flash

검색 범위: 최근 30일

AI/ML 연구자를 위한 arXiv 리서치 어시스턴트입니다. 최근 30일 이내 후보 논문 중 SLM, 엣지 디바이스, PEFT(LoRA, QLoRA, 어댑터 미세 조정)를 활용하여 특정 출력 형식(구조화된 출력, JSON/스키마, 함수 호출 등)을 따르게 하는 논문을 우선 선별했습니다.

---

## [논문] 논문 1

1. 제목: TellTale: Blending Multi-Instance LoRA Text Encoders and a Zero-Shot LLM Judge for Ambivalence/Hesitancy Recognition in Videos
2. 저자: Abdel-Karim Al-Tamimi, Ali Rodan
3. 카테고리: Deployment/Quantization/Efficiency
4. 관련성 판단: 이 논문은 양자화된 SLM(14B LLM)과 LoRA 기반 PEFT를 활용하여 엣지 환경에 준하는 효율성을 추구하며, LLM이 특정 지시(rating)에 따라 응답을 생성하는 방식으로 특정 출력 형식 준수와 관련성이 높습니다.
5. 초록 요약 (3-4문장): TellTale은 인터뷰 영상에서 양가감정/망설임(A/H)을 인식하기 위한 텍스트 전용 접근 방식입니다. 이 방법은 LoRA 어댑터로 미세 조정된 두 개의 텍스트 인코더와, 양자화된 14B 인스트럭션 LLM을 제로샷 평가자로 활용하여 세 가지 확률 스트림을 결합합니다. LLM은 각 스크립트에 대해 A/H를 평가하도록 프롬프트되어 특정 형식의 출력을 유도하며, 이는 비전 기반 기준선보다 훨씬 높은 Macro-F1 점수를 달성합니다. 이 연구는 효율적인 모델 활용과 지시 기반 응답 생성을 결합한 접근 방식을 제시합니다.
6. 서론/앞부분 기반 판단: 제공된 서론/앞부분 텍스트가 없어 초록을 기반으로 판단합니다. 이 연구는 LoRA를 활용한 PEFT와 양자화된 SLM을 결합하여 특정 태스크(A/H 인식)를 수행하며, LLM이 특정 형식(평가)의 출력을 생성하도록 지시하는 점이 핵심입니다. 이는 리소스 제약 환경에서 SLM을 효율적으로 활용하고, 지시를 통해 원하는 형식의 응답을 얻는 데 중요한 시사점을 제공합니다.
7. 핵심 기여사항:
  - \* LoRA 어댑터로 미세 조정된 텍스트 인코더와 양자화된 14B 인스트럭션 LLM을 결합한 하이브리드 접근 방식 제안.
  - \* LLM을 제로샷 평가자로 활용하여 특정 형식의 출력(A/H 평가)을 유도하는 방법론 제시.
  - \* BAH 데이터셋에서 비전 기반 기준선 대비 우수한 성능 달성.
8. 실험 결과: 주최 측이 채점한 비공개 테스트 세트에서 Macro-F1 0.7364 및 평균 정밀도 0.7940을 달성하여 공식 비전 기반 기준선(Macro-F1 0.2827)보다 크게 향상된 성능을 보였습니다.
9. 내 연구와의 관련성: SLM을 엣지 환경에서 효율적으로 배포하고, LoRA를 활용하여 특정 태스크에 맞게 미세 조정하며, 특히 LLM이 지시를 통해 구조화된 형태의 응답(예: 평가 점수, 특정 레이블)을 생성하도록 만드는 방법에 대한 아이디어를 얻을 수 있습니다. 양자화된 LLM의 활용은 리소스 제약 환경에 적합합니다.
10. 확인해야 할 부분: LLM이 생성하는 "평가"의 구체적인 형식(예: 숫자 점수, 특정 텍스트 레이블)과 그 구조화 정도. LoRA 어댑터가 텍스트 인코더에 어떻게 적용되었는지, 그리고 양자화된 LLM의 추론 지연 시간 및 메모리 사용량에 대한 상세 정보.
11. arXiv PDF: <https://arxiv.org/pdf/2607.16635.pdf>

[논문] 논문 2

1. 제목: Three-Pronged Spectral Control for Federated Parameter Efficient Fine Tuning
2. 저자: Shiva Raj Pokhrel, Dipsan Bhattarai, Anwar Walid
3. 카테고리: Format-LoRA/Structured Output
4. 관련성 판단: LLaMA3.2-1B와 같은 SLM을 LoRA 기반 PEFT를 사용하여 연합 학습(엣지 환경)에서 효율적이고 견고하게 미세 조정하는 방법론을 제시합니다. 특정 출력 형식에 대한 직접적인 언급은 없으나, SLM, PEFT, 엣지 환경의 핵심 목표와 부합합니다.
5. 초록 요약 (3-4문장): 연합 매개변수 효율적 미세 조정(PEFT)은 분산된 엣지 데이터에서 대규모 사전 학습 모델을 통신 효율적으로 적응시키지만, 비-IID 클라이언트 이질성 하에서는 취약합니다. 이 논문은 견고한 연합 PEFT를 위한 스펙트럼 제어 프레임워크인 TRISHUL을 제안합니다. TRISHUL은 공유된 고정 다중 헤드 저랭크 기반을 사용하여 압축된 코어 업데이트의 대수적으로 정확한 집계를 얻고, 업로드 전에 클라이언트별 고랭크 스펙트럼 구성 요소를 억제하기 위해 핵 노름 근접 축소를 적용합니다. 이 방법은 LLaMA3.2-1B를 포함한 다양한 벤치마크에서 연합 LoRA 기준선 대비 수렴, 안정성 및 최종 성능을 향상시킵니다.
6. 서론/앞부분 기반 판단: 제공된 서론/앞부분 텍스트가 없어 초록을 기반으로 판단합니다. 이 연구는 LLaMA3.2-1B와 같은 SLM을 연합 학습 환경에서 LoRA를 포함한 PEFT 기법을 사용하여 효율적이고 견고하게 미세 조정하는 데 중점을 둡니다. 이는 엣지 디바이스에 SLM을 배포하고 지속적으로 업데이트해야 하는 시나리오에서 중요한 문제인 데이터 이질성 및 통신 효율성을 다룹니다.
7. 핵심 기여사항:
  - \* 비-IID 클라이언트 이질성 하에서 연합 PEFT의 견고성을 향상시키는 TRISHUL 스펙트럼 제어 프레임워크 제안.
  - \* 공유된 고정 다중 헤드 저랭크 기반을 통한 정확한 LoRA 업데이트 집계.
  - \* 핵 노름 근접 축소를 통한 클라이언트별 고랭크 스펙트럼 구성 요소 억제 및 레이어별 적응 헤드 불균일 할당.
8. 실험 결과: CIFAR-100, SVHN, 20 Newsgroups, MRQA, GLUE 벤치마크에서 LLaMA3.2-1B를 포함하여 연합 LoRA 기준선 대비 수렴, 안정성 및 최종 성능이 향상되었으며, 이질성이 강할수록 더 큰 이득을 보였습니다.
9. 내 연구와의 관련성: 엣지 디바이스 환경에서 SLM을 LoRA와 같은 PEFT 기법을 사용하여 연합 학습 방식으로 효율적이고 안정적으로 미세 조정하는 방법에 대한 통찰을 제공합니다. 특히 데이터 이질성 문제를 해결하고 통신 효율성을 높이는 방법은 실제 엣지 배포 시 중요한 고려 사항입니다.
10. 확인해야 할 부분: 이 논문에서 다루는 LLaMA3.2-1B 모델의 구체적인 엣지 디바이스 배포 시나리오 및 성능 지표(예: 추론 지연 시간, 메모리 사용량). 스펙트럼 제어 기법이 모델의 특정 출력 형식 준수 능력에 미치는 영향.
11. arXiv PDF: <https://arxiv.org/pdf/2607.20914.pdf>

[논문] 논문 3

1. 제목: Recti-Q: Feature-Space Rectification for Out-of-Distribution-Robust Quantized Perception in Edge Robotics
2. 저자: Hamidreza Yaghoubi Araghi, Parastoo Pilevar, Ming C. Lin
3. 카테고리: Deployment/Quantization/Efficiency
4. 관련성 판단: 엣지 디바이스, 양자화, PEFT(LoRA) 및 효율성 측면에서 매우 높은 관련성을 가집니다. 비록 SLM이 아닌 비전 트랜스포머를 다루지만, 그 방법론(양자화된 백본 + LoRA 어댑터)은 SLM의 엣지 배포에 직접적으로 적용될 수 있습니다.

5. 초록 요약 (3-4문장): 로봇 지각 파이프라인은 SWaP(Size, Weight, and Power) 제약이 있는 엣지 플랫폼에 배포되는 대규모 비전 백본에 의존하며, 실시간 추론을 위해 PTQ(Post-Training Quantization)가 매력적입니다. 그러나 PTQ는 배포 관련 분포 변화(OOD) 하에서 신뢰성을 크게 저하시킬 수 있습니다. 이를 해결하기 위해 Recti-Q는 양자화된 백본을 고정하고 소스 데이터만을 사용하여 작은 분류기 헤드 LoRA 어댑터를 훈련하는 경량 특징 공간 정류 프레임워크를 제안합니다. Recti-Q는 1% 미만의 파라미터 오버헤드(6KB)로 PTQ 메모리 절감 효과를 유지하고, 계산량을 거의 추가하지 않으며, 배포된 로봇 플릿을 위한 저대역폭 OTA(Over-The-Air) 복원력 패치를 가능하게 합니다.

6. 서론/앞부분 기반 판단: 이 연구는 로봇 공학 분야에서 엣지 디바이스에 대규모 비전 모델을 배포할 때 발생하는 양자화로 인한 OOD(Out-of-Distribution) 견고성 저하 문제를 해결하고자 합니다. 이를 위해 양자화된 모델의 백본을 고정한 채 작은 LoRA 어댑터만 미세 조정하는 PEFT 방식을 사용하며, 이는 SLM을 엣지 디바이스에 효율적으로 배포하고 적응시키는 데 필요한 핵심 기술(양자화, PEFT, 저메모리/저연산)과 일치합니다.

7. 핵심 기여사항:

- \* 양자화로 인한 OOD 견고성 저하("Quantization-Induced Robustness Gap") 문제 식별 및 정량화.
- \* 양자화된 백본을 고정하고 작은 LoRA 어댑터를 훈련하여 특징 공간을 정류하는 경량 Recti-Q 프레임워크 제안.
- \* 1% 미만의 파라미터 오버헤드로 높은 메모리 절감 효과 유지 및 저대역폭 OTA 패치 가능.

8. 실험 결과: 4비트 PTQ 모델에서 나타나는 견고성 저하를 Recti-Q가 상당 부분 회복하며, 일부 경우 FP32 성능과 일치하거나 초과하는 결과를 보였습니다. 파라미터 오버헤드는 1% 미만(최소 6KB)이며, 99% 이상의 PTQ 메모리 절감 효과를 유지하고 계산량을 거의 추가하지 않았습니다.

9. 내 연구와의 관련성: SLM을 엣지 디바이스에 배포할 때 양자화와 LoRA를 결합하여 모델의 효율성을 극대화하고, 동시에 실제 환경의 분포 변화에 대한 견고성을 확보하는 방법에 대한 실질적인 접근 방식을 제공합니다. 특히 LoRA 어댑터의 극도로 낮은 파라미터 오버헤드와 OTA 업데이트 가능성은 TinyML 환경에 매우 적합합니다.

10. 확인해야 할 부분: 이 방법론이 비전 모델 외에 SLM에 적용될 때의 성능 및 효율성 변화. LoRA 어댑터가 어떤 레이어에 적용되었는지, 그리고 양자화된 모델의 출력 품질에 미치는 영향.

11. arXiv PDF: <https://arxiv.org/pdf/2607.18540.pdf>