

# SLM / Edge Device arXiv Daily Summary

생성일: 2026-09-01 08:18 KST

Gemini 모델: gemini-2.5-flash

검색 범위: 최근 30일

## [논문] 논문 1

1. 제목: From Documents to Reasoning: A Validated Synthetic Data Pipeline and Semantic-Aware Fine-Tuning for Financial Numerical Reasoning

2. 저자: Lokendra Birla, Milind Savagaonkar, Visnu Srinivasan, Sowmya Rasipuram, Shubhashis Sengupta

3. 카테고리: SLM/Edge/On-device, Deployment/Quantization/Efficiency

4. 관련성 판단: 이 논문은 SLM(Small Language Models)을 QLoRA를 사용하여 파인튜닝하여 금융 분야의 수치 추론 능력을 향상시키는 데 중점을 둡니다. 특히 복잡한 데이터 형식과 수치적 정확성을 요구하는 금융 QA 태스크에서 모델의 일관성과 신뢰성을 높이는 것을 목표로 합니다. 이는 SLM, PEFT(QLoRA), 그리고 특정 형식(수치 표현식)의 출력을 다루므로 핵심 목표에 매우 부합합니다.

5. 초록 요약: 이 연구는 금융 질문 답변(QA) 시스템의 성능을 개선하기 위한 포괄적인 파이프라인을 제안합니다. 고품질 합성 데이터 생성과 QLoRA를 활용한 SLM 파인튜닝을 결합하여, 복잡한 금융 문서에서 수치 추론의 정확도를 높입니다. 특히, 표준 평가 지표의 한계를 극복하기 위해 산술 표현식 기반의 새로운 평가 지표와 의미론적 유사성을 활용한 수정된 손실 함수를 도입하여 모델의 추론 능력을 보다 정확하게 반영합니다.

6. 서론/앞부분 기반 판단: 서론에서는 LLM이 금융 문서의 복잡한 데이터 형식(표, 차트, 텍스트)에서 다단계 추론 및 정확한 산술 계산을 수행하는 데 어려움이 있음을 지적합니다. 특히 LLM의 방대한 크기로 인해 대규모 배포 비용이 높다는 문제의식을 가지고, LLM이 생성한 추론 데모를 활용하여 SLM을 파인튜닝하는 접근 방식의 중요성을 강조합니다. 또한, 기존의 Exact Match(EM) 평가 방식이 단위나 형식의 미묘한 차이를 간과하여 성능 평가를 오도할 수 있음을 문제로 제기하며, 이를 해결하기 위한 새로운 평가 지표의 필요성을 언급합니다.

7. 핵심 기여사항:

- \* 고품질 합성 데이터 생성 및 검증 파이프라인 제안.
- \* QLoRA를 활용한 SLM 파인튜닝을 통해 금융 QA 성능 향상.
- \* 산술 표현식 계산 기반의 새로운 평가 지표 및 의미론적 유사성을 활용한 수정된 손실 함수 도입.

8. 실험 결과: ConvFinQA 벤치마크 데이터셋에서 합성 데이터셋과 제안된 손실 함수를 사용한 파인튜닝 후 QA 정확도에서 상당한 개선을 보였습니다.

9. 내 연구와의 관련성: SLM을 엣지 디바이스에 배포하기 위해 QLoRA와 같은 PEFT 기법을 활용하고, 특정 도메인(금융 수치 추론)에서 구조화된 출력(산술 표현식)의 정확성을 높이는 방법을 제시한다는 점에서 매우 관련성이 높습니다. 특히, 출력 형식의 정확성을 평가하고 개선하는 새로운 접근 방식은 내 연구에 영감을 줄 수 있습니다.

10. 확인해야 할 부분:

- \* 합성 데이터 생성 및 검증 파이프라인의 구체적인 구현 방식.
- \* 새로운 평가 지표와 손실 함수가 SLM의 출력 형식 준수에 미치는 영향.
- \* QLoRA 적용 시 메모리 및 추론 지연 시간 절감 효과에 대한 상세 분석.

11. arXiv PDF: <https://arxiv.org/pdf/2608.27919.pdf>

## [논문] 논문 2

1. 제목: Acquire, Repair, Preserve: A Diagnosis-Guided Post-Training Recipe for Small-Model Dialogue Game Agents
2. 저자: Nan Li
3. 카테고리: Format-LoRA/Structured Output
4. 관련성 판단: 이 논문은 2B 규모의 소형 언어 모델(SLM)을 대화형 게임 에이전트로 활용하며, 모델이 상태를 유지하고 피드백을 해석하며 유효한 행동을 선택하도록 훈련하는 방법을 다룹니다. 특히 "잘못된 형식의 행동(malformed actions)" 및 "피드백 위반"과 같은 출력 형식 준수 문제를 해결하기 위해 SFT 및 턴-로컬 선호도 쌍을 사용한 파인튜닝을 적용하므로, SLM, PEFT, 그리고 출력 형식 준수라는 핵심 목표에 매우 적합합니다.
5. 초록 요약: 대화형 게임 환경에서 2B 규모의 소형 언어 모델의 성능을 개선하기 위한 3단계 훈련 레시피를 제안합니다. 모델의 실패 원인(반복된 추측, 잘못된 형식의 행동, 피드백 위반 등)을 진단하고, 이를 바탕으로 광범위한 게임 참여를 위한 SFT, 특정 대화 게임 내에서 기계적으로 검증 가능한 실패를 수정하기 위한 턴-로컬 선호도 쌍 학습, 그리고 일반적인 능력 보존 단계를 거칩니다. 이 접근 방식은 모델의 상호작용 능력을 크게 향상시키면서도 일반적인 성능을 유지합니다.
6. 서론/앞부분 기반 판단: 서론에서는 대화형 게임이 정적 벤치마크가 암묵적으로 남겨둔 모델의 능력, 즉 턴에 걸쳐 상태를 유지하고, 피드백을 해석하며, 변화하는 제약 조건 하에서 유효한 행동을 선택하는 능력을 테스트한다고 설명합니다. 특히 소형 모델(2B)이 이러한 설정에 적합하지만, 상호작용 행동이 취약하며 "잘못된 형식의 행동"이나 "피드백 위반"과 같은 문제가 자주 발생함을 지적합니다. 이러한 오류가 빈번하고 기계적으로 확인 가능하며 특정 결정에 국한된다는 점을 바탕으로, 모델에게 전체 대화를 다시 가르치는 것이 아니라 실패하는 특정 결정에 감독을 집중하는 훈련 질문을 던집니다.
7. 핵심 기여사항:
  - \* 소형 대화형 게임 에이전트를 위한 진단 기반의 3단계 훈련 레시피(획득, 수정, 보존) 제안.
  - \* SFT와 턴-로컬 선호도 쌍을 활용하여 모델의 "잘못된 형식의 행동" 및 "프로토콜 준수" 문제 해결.
  - \* 상호작용 성능을 크게 개선하면서도 일반적인 정적 성능을 보존하는 방법론 제시.
8. 실험 결과: 공식 최종 평가에서 공개 clemscore를 10.67에서 38.92로, 폐쇄형 도메인 점수를 13.41에서 41.17로 향상시켰으며, 기준 모델의 종합 정적 성능(44.24)을 거의 보존(44.14)했습니다. 가장 큰 개선은 대상 게임 계열의 미확인 변형에서 나타났습니다.
9. 내 연구와의 관련성: 옛지 디바이스에서 소형 모델이 특정 대화 형식이나 행동 프로토콜을 정확히 따르도록 만드는 데 필요한 파인튜닝 전략에 대한 통찰을 제공합니다. 특히 "malformed actions"와 같은 출력 형식 오류를 진단하고 수정하는 접근 방식은 내 연구의 structured output/function calling 문제 해결에 직접적인 도움이 될 수 있습니다.
10. 확인해야 할 부분:
  - \* "턴-로컬 선호도 쌍"을 구성하고 학습시키는 구체적인 방법.
  - \* 다양한 출력 형식(JSON, schema 등)에 이 접근 방식을 어떻게 적용할 수 있을지.
  - \* 모델의 "프로토콜 준수"를 측정하는 상세한 메트릭.
11. arXiv PDF: <https://arxiv.org/pdf/2608.28458.pdf>

## [논문] 논문 3

1. 제목: Learning to Use Tools: Reinforcement Learning for Tool-Integrated Mathematical Reasoning
2. 저자: Minghui Xu, Zi Wang
3. 카테고리: Format-LoRA/Structured Output
4. 관련성 판단: 이 논문은 LLM이 외부 도구를 통합하여 수학적 추론 능력을 향상시키는 방법을 연구합니다. 특히 계산기 도구

호출을 통해 모델이 정확한 계산과 검증을 수행하도록 훈련하며, 이는 "function calling" 및 "tool calling"이라는 핵심 목표에 직접적으로 부합합니다. SFT와 강화 학습을 사용하여 도구 사용 패턴을 학습시키므로 PEFT 기법과도 관련이 있습니다.

5. 초록 요약: LLM의 외부 도구 통합을 통해 수학적 추론 능력을 개선하는 방법을 연구하며, Countdown 태스크에서 계산기 도구 호출을 활용합니다. 계산 오류가 응답 실패의 상당 부분을 차지함을 분석한 후, 유용한 도구 사용 패턴과 반환된 출력을 해석하는 방법을 모델에 가르치기 위해 SFT 데이터셋을 구축합니다. 이 도구 형식 정책을 기반으로, 자동으로 검증 가능한 최종 답변 보상을 사용하여 RLOO, RLOO++, GRPO, DAPO 등 여러 온-폴리시 강화 학습 방법을 적용합니다.

6. 서론/앞부분 기반 판단: 서론에서는 LLM이 코딩 및 수학적 추론에서 뛰어난 능력을 보이지만, 특히 정확한 수치 계산이 필요한 다단계 문제에서 산술적 및 논리적 실수를 저지룰 수 있음을 지적합니다. 이는 토큰화 및 자동회귀적 다음 토큰 예측 방식이 신뢰할 수 있는 계산이나 검증을 위한 명시적인 메커니즘을 제공하지 않기 때문이라고 설명합니다. 이러한 한계를 극복하기 위해 외부 도구 통합이 정확한 계산이 필요한 태스크에서 LLM의 신뢰성을 향상시키는 중요한 방향임을 강조하며, Countdown 태스크를 통해 도구 통합 수학적 추론을 연구합니다.

7. 핵심 기여사항:

- \* 실시간 계산기 실행을 포함하는 도구 통합 Countdown 훈련 및 평가 파이프라인 구축.
- \* 도구 통합이 SFT 및 RL 모델 모두의 성능을 일관되게 향상시킴을 입증.
- \* Tool-DAPO가 테스트된 방법 중 가장 강력한 성능을 달성함을 보여줌.
- \* RL이 최종 답변 보상만 제공될 때도 더 효과적인 도구 사용을 장려함을 분석.

8. 실험 결과: 계산기 도구 통합은 SFT 및 RL 기준선 모두에서 pass@k 전반에 걸쳐 약 10%p의 성능 향상을 가져왔습니다. RL 방법 중 Tool-DAPO는 Tool-SFT의 pass@1 35.8%에서 66.0%로 향상시키며 가장 강력한 성능을 달성했습니다.

9. 내 연구와의 관련성: LLM이 특정 도구(계산기)를 호출하고 그 결과를 해석하여 추론을 개선하는 방식은 내 연구의 "function calling" 및 "tool calling" 목표에 매우 직접적으로 관련됩니다. 특히 SFT와 RL을 통해 모델이 도구 사용 패턴을 학습하고 특정 형식(예: `...</tool>` 태그)으로 도구를 호출하도록 만드는 방법은 오티지 디바이스의 SLM이 외부 기능과 상호작용하는 데 중요한 통찰을 제공할 수 있습니다.

10. 확인해야 할 부분:

- \* 도구 호출을 위한 특정 프롬프트 또는 템플릿 형식.
- \* SLM에 이 접근 방식을 적용할 때의 성능 및 효율성 트레이드오프.
- \* 다양한 종류의 도구(JSON 스키마 기반 API 등)에 대한 확장 가능성.

11. arXiv PDF: <https://arxiv.org/pdf/2608.28447.pdf>