SLM / Edge Device arXiv Daily Summary

생성일: 2026-10-17 07:12 KST

Gemini 모델: gemini-2.5-flash

검색 범위: 최근 30일

[논문] 논문 1

1. 제목: Progress-Aware Distillation for Mitigating Stagnation in Small Language Model Agents
2. 저자: Yuanpu Cao, Saket Sathe, Hanyu Wang, Ziyi Yin, Fenglong Ma, Jinghui Chen
3. 카테고리: SLM/Edge/On-device, Deployment/Quantization/Efficiency
4. 관련성 판단: SLM 에이전트의 효율적인 배포를 위해 SFT 기반 증류를 사용하며, 특히 툴 호출과 같은 에이전트의 구조화된 출력 형식 준수 및 장기 추론 과정에서의 성능 저하 문제를 다룹니다.
5. 초록 요약: LLM 기반 에이전트 시스템은 복잡한 작업을 잘 수행하지만, 높은 토큰 소비와 추론 지연 시간으로 인해 실제 배포에 제약이 있습니다. 이를 해결하기 위해 대규모 모델의 에이전트 능력을 SLM으로 전이하는 SFT 기반 증류가 연구되지만, 긴 상호작용 궤적에서 SLM 에이전트가 비생산적인 루프에 빠지는 '진행 정체' 현상을 겪습니다. 이 논문은 학생 에이전트의 궤적에서 정체를 명시적으로 감지하고 페널티를 부여하는 Progress-Aware Distillation (ProD)을 제안하여, SLM 에이전트의 성공률과 작업 완료 효율성을 향상시킵니다.
6. 서론/앞부분 기반 판단: LLM 에이전트의 높은 비용과 지연 시간 문제를 해결하기 위해 SLM으로 에이전트 능력을 전이하는 SFT 기반 증류가 중요해지고 있습니다. 그러나 SLM 에이전트는 긴 추론-액션 체인과 환경 피드백이 축적될 때 '진행 정체' 현상을 겪으며, 이는 실패한 전략을 반복하고 의미 있는 진전을 이루지 못하게 합니다. 이 연구는 이러한 정체 현상을 체계적으로 분석하고, 이를 완화하여 SLM 에이전트가 교사 모델의 행동을 점진적으로 모방하도록 돕는 ProD 프레임워크를 제안합니다. 이는 SLM이 복잡한 에이전트 작업을 수행할 때 필요한 일관되고 정확한 행동(툴 호출과 같은 구조화된 출력 포함)을 생성하는 데 중요한 문제의식을 반영합니다.
7. 핵심 기여사항:
* SLM 에이전트의 장기 상호작용에서 발생하는 '진행 정체' 현상을 식별하고 체계적으로 분석했습니다.
* 학생 에이전트의 궤적에서 정체를 명시적으로 감지하고 페널티를 부여하는 Progress-Aware Distillation (ProD) 프레임워크를 제안했습니다.
* 학생과 교사 간의 정체 차이를 적응형 마진으로 인코딩하여 최적화 강도를 동적으로 조절하는 방법을 제시했습니다.
8. 실험 결과: 0.6B에서 8B에 이르는 8개 SLM에 대한 광범위한 실험을 통해 ProD가 진행 정체를 크게 완화하고, 증류된 SLM 에이전트의 성공률과 작업 완료 효율성을 향상시킴을 입증했습니다.
9. 내 연구와의 관련성: (여기에 연구자님의 관련성을 작성해주세요)
10. 확인해야 할 부분: (여기에 추가로 확인하고 싶은 부분을 작성해주세요)
11. arXiv PDF: https://arxiv.org/pdf/2610.19439.pdf

[논문] 논문 2

1. 제목: DocPilot: Interactive Agent Orchestration and Training for Long Visual Document Understanding
2. 저자: Zhuowen Liang, Xiaotian Lin, Yuyu Luo, Haixun Wang, Nan Tang
3. 카테고리: SLM/Edge/On-device
4. 관련성 판단: SLM을 활용하여 긴 시각 문서 이해를 위한 에이전트 시스템을 구축하며, 특히 페이지 탐색, 증거 지역화, 코드

기반 추론 등 툴 호출과 유사한 구조화된 상호작용 및 출력을 학습시키는 데 중점을 둡니다.
5. 초록 요약: 멀티모달 긴 문서 질의응답은 모델이 페이지와 모달리티를 넘나들며 증거를 찾고, 이질적인 콘텐츠를 이해하며, 수집된 증거를 바탕으로 추론해야 하는 복잡한 작업입니다. 기존 VLM과 문서 에이전트는 이러한 작업에 한계가 있어, 이 논문은 표현력이 풍부한 오케스트레이션을 지원하고 SLM이 복잡한 문서 해결을 학습할 수 있도록 하는 에이전트 문서 프레임워크 DocPilot을 소개합니다. DocPilot은 페이지 수준 탐색 및 세분화된 증거 지역화를 통해 증거 탐색을 조율하고, 로컬 시각 검사, 코드 기반 수치 추론, 교차 모달 추론을 통합합니다. 이러한 능력을 SLM에 전이하기 위해 데이터 기반 추론 궤적 및 실행 가능한 상호작용 궤적을 통한 커리큘럼 기반 에이전트 훈련을 제안합니다.
6. 서론/앞부분 기반 판단: 실제 문서 지능 분야에서 멀티모달 긴 문서 질의응답은 핵심적인 문제이지만, 기존 VLM조차 분산된 증거를 놓치거나 교차 모달 추론에 어려움을 겪습니다. 기존 문서 에이전트 또한 미리 정의된 워크플로우나 거친 액션에 의존하여 유연성이 부족합니다. 이러한 문제의식 하에, DocPilot은 인간의 독서 과정처럼 증거 탐색과 멀티모달 이해를 반복적으로 수행하는 에이전트 프레임워크를 제안합니다. 특히 SLM이 이러한 복잡한 에이전트 능력을 학습하도록 커리큘럼 기반 훈련을 통해 툴 호출과 같은 구조화된 상호작용을 가능하게 하는 것이 목표입니다.
7. 핵심 기여사항:
* 표현력이 풍부한 오케스트레이션을 지원하고 SLM이 복잡한 문서 해결을 학습할 수 있는 에이전트 문서 프레임워크 DocPilot을 제안했습니다.
* 페이지 수준 탐색, 세분화된 증거 지역화, 로컬 시각 검사, 코드 기반 수치 추론, 교차 모달 추론을 통합하는 증거 탐색 및 멀티모달 이해 조율 방식을 개발했습니다.
* 단일 능력 학습에서 적응형 오케스트레이션으로 진행되는 커리큘럼 기반 에이전트 훈련을 통해 SLM에 에이전트 능력을 전이했습니다.
8. 실험 결과: MMLongBench-Doc, DocBench, FinRAGBench-V, MADQA 벤치마크에서 DocPilot은 최첨단 VLM 백본으로 강력한 성능 향상을 달성했으며, DocPilot-4B는 훨씬 더 큰 모델에 필적하는 경쟁력 있는 성능을 보여 다양한 긴 문서 추론 설정에서 강력한 효과와 일반화 능력을 입증했습니다.
9. 내 연구와의 관련성: (여기에 연구자님의 관련성을 작성해주세요)
10. 확인해야 할 부분: (여기에 추가로 확인하고 싶은 부분을 작성해주세요)
11. arXiv PDF: https://arxiv.org/pdf/2610.21327.pdf

[논문] 논문 3

1. 제목: ixi-sLM: On-Device sLM for AI Call Agent Service
2. 저자: Han-Sang Lee, Kyuho Lee, Juneyoung Park, Seongbae Lee, Jin Kyu Park, Minjae Kim, Yuri Hong, Jinwoo Lee, Youngwook Kwon, Seongwan Kim, Seungheon Hyeon, Jaeho Lee, Kiduk Kwon
3. 카테고리: SLM/Edge/On-device, Deployment/Quantization/Efficiency
4. 관련성 판단: 온디바이스 환경에서 AI 통화 에이전트 서비스를 위한 SLM을 개발하며, 엄격한 메모리 및 지연 시간 제약 하에 도메인 적응 모델링 및 양자화를 통해 클라우드 수준의 품질을 달성하는 데 중점을 둡니다. 이는 특정 서비스(통화 요약, 통화 응답)를 위한 구조화된 응답 형식 준수와 밀접하게 관련됩니다.
5. 초록 요약: 온디바이스 AI 통화 에이전트는 개인 정보 보호, 네트워크 독립성, 클라우드 비용 절감 등의 이점을 제공하지만, 1GiB 메모리 예산, 통화 중 지연 시간 및 발열 제한, 정적 정수 NPU 실행, 사전 훈련과 다른 한국어 STT 입력, 클라우드 수준의 품질 기대치 등 현실적인 제약에 직면합니다. 이 논문은 1.2B 한국어 SLM인 ixi-sLM을 모바일 NPU에 배포하기 위해 도메인 적응 모델링과 태스크 인식 양자화를 사용합니다. 도메인 적응 모델링은 임베딩 및 LM 헤드를 축소하고 토크나이저를 통화 음성에 재적합하며, 태스크 인식 양자화는 실제 통화 데이터를 기반으로 모듈별 혼합 정밀도를 할당합니다.

6. 서론/앞부분 기반 판단: (PDF 앞부분/서론 일부 텍스트가 제공되지 않았으므로 초록을 기반으로 판단) 온디바이스 AI 통화 에이전트 서비스는 개인 정보 보호와 비용 효율성 측면에서 중요하지만, 모바일 환경의 엄격한 하드웨어 제약(메모리, NPU, 발열 등)과 언어 모델의 사전 훈련 데이터와 다른 실제 통화 데이터의 특성으로 인해 클라우드 수준의 서비스 품질을 달성하기 어렵다는 문제의식을 가지고 있습니다. 이 연구는 이러한 제약을 극복하고 온디바이스 SLM이 실제 서비스에서 요구되는 높은 품질의 응답을 생성할 수 있도록 도메인 적응 모델링과 태스크 인식 양자화 기법을 통해 모델을 최적화하는 데 초점을 맞춥니다. 이는 특정 서비스 목적에 맞는 구조화되거나 제어된 출력 형식을 안정적으로 생성하는 데 기여합니다.
7. 핵심 기여사항:
* 온디바이스 AI 통화 에이전트 서비스를 위한 1.2B 한국어 SLM인 ixi-sLM을 개발하고 모바일 NPU에 배포했습니다.
* 도메인 적응 모델링을 통해 임베딩 및 LM 헤드 크기를 줄이고 토크나이저를 통화 음성에 재적합하여 모델 크기 및 효율성을 최적화했습니다.
* 태스크 인식 양자화를 통해 실제 통화 데이터를 기반으로 모듈별 혼합 정밀도를 할당하여 온디바이스에서 클라우드 수준의 품질을 달성했습니다.
8. 실험 결과: 단일 도메인 적응 모델이 ixi-O의 두 가지 프로덕션 서비스(AI 통화 요약 및 AI 통화 응답)에서 최첨단 클라우드 LLM의 태스크 가중치 품질의 94%를 달성했습니다. 온디바이스 모델링은 전체 점수에서 미미한 하락만으로 NPU에서 해당 품질을 유지하며, 803MiB 모델(FP16의 28%)로 CPU당 통화 에너지의 23%만 소비했습니다. 동일한 방법론이 Qualcomm 및 Apple NPU에 배포되어 수백만 명의 ixi-O 가입자에게 서비스 중입니다.
9. 내 연구와의 관련성: (여기에 연구자님의 관련성을 작성해주세요)
10. 확인해야 할 부분: (여기에 추가로 확인하고 싶은 부분을 작성해주세요)
11. arXiv PDF: https://arxiv.org/pdf/2610.19382.pdf