SLM / Edge Device arXiv Daily Summary

생성일: 2026-10-22 07:38 KST

Gemini 모델: gemini-2.5-flash

검색 범위: 최근 30일

[논문] 논문 1

1. 제목: MedPAO-Assist: Edge-Deployable, Modality-Aware Agentic AI for Radiology Report Structuring
2. 저자: Shrish Shrinath Vaidya, Minmini Selvam, Ganapathy Krishnamurthi
3. 카테고리: SLM/Edge/On-device, Deployment/Quantization/Efficiency
4. 관련성 판단: 이 논문은 0.6B 파라미터의 SLM을 엣지 디바이스(표준 랩톱 CPU)에 배포하여 PEFT 방법론을 활용, 방사선 보고서를 구조화된 형식으로 생성하는 것을 목표로 한다. 이는 SLM, 엣지 배포, PEFT, 그리고 특정 출력 형식(구조화된 보고서) 준수라는 핵심 목표에 완벽하게 부합하며, 메모리 및 지연 시간 최적화에 대한 구체적인 수치를 제시하여 엣지 환경에서의 실현 가능성을 강력하게 보여준다.
5. 초록 요약: MedPAO-Assist는 독점 클라우드 모델이나 고성능 GPU를 요구하는 대규모 모델의 한계를 극복하기 위해 엣지 배포 가능한 에이전트 프레임워크를 제안한다. 이 시스템은 약 0.6B 파라미터의 SLM을 사용하여 방사선 전문의의 구술 및 음성 명령으로부터 구조화된 방사선 보고서를 생성하며, 표준 랩톱 CPU에서 약 3.3GB의 최대 RAM과 약 31초의 평균 종단 간 지연 시간을 달성한다. 개념 추출, SNOMED-CT 그라운딩, 구조화된 보고서 생성 및 음성 기반의 인간 개입 수정 단계를 포함하는 다중 에이전트 아키텍처를 통해 키보드 입력이나 외부 API 호출 없이 완전한 "노터치" 보고 워크플로우를 제공한다.
6. 서론/앞부분 기반 판단: 서론에서는 기존 LLM 기반 방사선 보고서 구조화 시스템이 데이터 프라이버시 및 오프라인 작동이 필수적인 임상 환경에서 클라우드 기반 또는 고성능 GPU 요구사항으로 인해 채택에 병목 현상이 있음을 지적한다. 또한, 수동 구조화 또는 자동 생성된 보고서 수정의 시간 소모적인 특성과 기존 규칙 기반/전통 ML 모델의 일반화 부족 문제를 언급한다. 이러한 문제의식을 바탕으로 MedPAO-Assist는 SLM과 PEFT를 활용하여 낮은 지연 시간과 메모리 사용량으로 CPU 전용 엣지 배포를 가능하게 하고, 다중 에이전트 프레임워크를 통해 프로토콜을 준수하는 다중 모달리티 보고서 구조화를 목표로 한다.
7. 핵심 기여사항:
* 프로토콜 기반의 다중 모달리티 보고서 구조화를 위한 다중 에이전트 프레임워크(MAS) 제안.
* 의료 개념 추출 및 분류를 위한 SLM 및 PEFT 방법의 효율적인 활용.
* 최소한의 지연 시간과 메모리 공간으로 저자원 CPU 배포 달성.
* MAS와 ASR 통합을 통해 다중 모달리티, 프로토콜 준수, 터치 프리 보고 인터페이스 제공.
8. 실험 결과: 0.6B 파라미터 SLM을 사용하여 표준 랩톱 CPU에서 약 3.3GB의 최대 RAM과 약 31초의 평균 종단 간 지연 시간을 달성했다. 각 파이프라인 단계(개념 추출, 온톨로지 그라운딩, 개념 분류)를 개별적으로 평가했으며, 하드웨어 프로파일링 결과는 실시간 CPU 전용 임상 배포의 타당성을 입증한다.
9. 내 연구와의 관련성: SLM을 엣지 디바이스에 배포하여 특정 도메인(방사선 보고서)에서 구조화된 출력을 생성하는 데 PEFT를 활용하는 방식은 내 연구 목표와 매우 밀접하게 관련되어 있다. 특히 CPU 전용 배포 및 메모리/지연 시간 최적화에 대한 구체적인 접근 방식과 결과는 엣지 환경에서의 SLM 활용 방안을 모색하는 데 중요한 참고 자료가 될 것이다.
10. 확인해야 할 부분:
* PEFT 방법론의 구체적인 구현 방식 및 훈련 데이터셋 구성.
* 구조화된 보고서 출력 형식(JSON/XML 등)의 상세 정의 및 모델이 이를 얼마나 정확하게 따르는지.

* 다중 에이전트 아키텍처 내에서 SLM의 역할 및 각 에이전트 간의 상호작용 방식.
* "노터치" 워크플로우의 사용자 경험 및 임상적 유용성에 대한 정성적 평가.

11. arXiv PDF: https://arxiv.org/pdf/2610.26913.pdf

[논문] 논문 2

1. 제목: AgenticRoboRL: Bringing Coding-Agent Post-Training to Agentic Robotics
2. 저자: Xinxin Liu, Bingxin Xu, Wenrui Bao, Ming Li, Wentao Bao, Chen Chen, Yuzhang Shang
3. 카테고리: Format-LoRA/Structured Output
4. 관련성 판단: 이 논문은 9B 파라미터 모델을 로봇 플래너로 활용하여 SFT 및 RL 기반의 포스트 트레이닝과 어댑터를 통해 VLA 스킬 호출 및 제어 코드 생성과 같은 구조화된 출력을 생성하는 데 중점을 둔다. 이는 SLM(9B 모델), PEFT(SFT, RL, 어댑터), 그리고 특정 출력 형식(function calling, tool calling) 준수라는 핵심 목표와 잘 부합한다.
5. 초록 요약: AgenticRoboRL은 로봇 플래너의 자체 역량을 향상시키기 위한 포스트 트레이닝 프레임워크를 제안한다. 기존 로봇 시스템이 강력한 클로즈드 소스 모델에 의존하는 한계를 극복하기 위해, 이 프레임워크는 지도 미세 조정(SFT)과 다중 턴 강화 학습(RL)을 결합한다. 특히, 다양한 실행 메커니즘(VLA 스킬 호출 및 제어 코드 생성)을 수용하기 위해 하네스별 어댑터를 사용하여 플래너 상호작용과 작업 결과를 연결하며, 이를 통해 공통 RL 훈련 파이프라인을 가능하게 한다. 9B 파라미터 플래너의 성공률을 크게 향상시켜 외부 메모리 없이도 Codex (GPT-5.5)에 근접하는 성능을 달성한다.
6. 서론/앞부분 기반 판단: 서론에서는 에이전트 로봇 시스템이 복잡한 조작 작업을 수행하기 위해 플래너와 로봇 하네스를 결합하지만, 기존 연구는 주로 하네스 개선이나 외부 메모리 활용에 집중하고 플래너 자체의 역량 강화에는 소홀했음을 지적한다. 코딩 에이전트 분야에서 모델 자체의 포스트 트레이닝이 효과적이었던 점에 착안하여, 로봇 플래너에도 이 방법을 적용하고자 한다. 그러나 VLA 스킬 호출이나 제어 코드 생성 등 로봇 하네스마다 다른 실행 메커니즘을 지원해야 하는 복잡성을 문제로 인식하고, 이를 해결하기 위해 SFT와 RL을 결합하고 하네스별 어댑터를 사용하는 AgenticRoboRL 프레임워크를 제안한다.
7. 핵심 기여사항:
* 로봇 플래너의 자체 역량 강화를 위한 포스트 트레이닝 프레임워크 AgenticRoboRL 제안.
* 지도 미세 조정(SFT)과 다중 턴 강화 학습(RL)을 결합한 훈련 레시피.
* 다양한 로봇 하네스(VLA 스킬 호출, 제어 코드 생성)를 지원하기 위한 하네스별 어댑터 통합.
* 9B 파라미터 플래너의 작업 성공률을 크게 향상시켜 강력한 클로즈드 소스 모델에 근접하는 성능 달성.

8. 실험 결과: LIBERO-PRO 벤치마크에서 9B 파라미터 플래너의 성공률을 외부 메모리 없이 18.1%에서 71.0%로 향상시켰으며, 이는 외부 메모리를 사용한 Codex (GPT-5.5)의 72.1%에 근접하는 수치이다. SFT는 18.1%에서 65.1%로, RL은 71.0%로 추가 개선을 가져왔다.
9. 내 연구와의 관련성: SLM(9B 모델)을 활용하여 특정 도메인(로봇 제어)에서 PEFT(SFT, RL, 어댑터)를 통해 VLA 스킬 호출이나 제어 코드 생성과 같은 구조화된 출력을 유도하는 방식은 내 연구의 "function calling" 또는 "tool calling" 목표와 직접적으로 연결된다. 특히 어댑터를 사용하여 다양한 실행 메커니즘을 지원하는 아이디어는 다양한 출력 형식에 대한 적응성을 높이는 데 영감을 줄 수 있다.
10. 확인해야 할 부분:
* 하네스별 어댑터의 구체적인 구조 및 학습 방식.
* VLA 스킬 호출 및 제어 코드 생성의 출력 형식 정의 및 모델이 이를 얼마나 정확하게 따르는지.
* 로봇 환경에서의 추론 지연 시간 및 메모리 사용량에 대한 추가 정보.

* 강화 학습의 보상 함수 설계 및 데이터 수집 방식.

11. arXiv PDF: https://arxiv.org/pdf/2610.28589.pdf

[논문] 논문 3

1. 제목: Bud ContextCompact 2.0: Context Compaction for Agent Success and Accuracy with Small Language Models and Constrained Context Windows

2. 저자: Jithin VG, Ditto PS

3. 카테고리: SLM/Edge/On-device

4. 관련성 판단: 이 논문은 SLM(1.2B, 9B, 8B 파라미터)을 엣지 디바이스 및 제한된 컨텍스트 환경에서 사용하는 에이전트의 성공률과 정확도를 향상시키는 데 초점을 맞춘다. 직접적으로 PEFT/LoRA를 통한 출력 형식 준수를 다루지는 않지만, "tool-using agents"라는 개념은 function calling/tool calling과 밀접하게 관련되어 있으며, 엣지 환경에서의 SLM 활용에 대한 중요한 통찰을 제공한다.

5. 초록 요약: Bud ContextCompact 2.0은 SLM 및 제한된 추론 시스템에서 에이전트가 여러 턴에 걸쳐 작동할 때 컨텍스트 창이 부족해지는 문제를 해결하기 위한 컨텍스트 압축 기술을 설명한다. 이 기술은 오래된 턴을 요약으로 대체하여 세션을 지속할 수 있게 하며, 1.2B 및 9B 파라미터 모델의 정확도를 향상시키고, 27B 추론 모델을 사용한 SWE-bench Verified 작업에서 긴 세션의 해결률을 높였다. 컨텍스트 압축은 특히 CPU 추론을 포함한 다양한 하드웨어에서 모델과 컨텍스트 창이 동일하다면 정확도 결과가 전이될 수 있음을 주장하며, 시간 비용은 하드웨어에 따라 달라지므로 예산에 포함되어야 한다고 강조한다.

6. 서론/앞부분 기반 판단: 서론에서는 ReAct 스타일의 도구 사용 에이전트가 작업을 완료하기 위해 모델 호출과 도구 호출을 번갈아 수행하면서 대화 프롬프트가 계속 증가하여 모델의 컨텍스트 창을 초과하게 되는 문제를 제기한다. 특히 SLM이 단일 GPU, 데스크톱 가속기 또는 CPU에서 8K~64K 토큰의 제한된 컨텍스트 창으로 실행될 때 이러한 문제가 더욱 심각해진다고 지적한다. 기존 컨텍스트 관리 방법(요약, 잘라내기 등)이 손실을 발생시키고 모델 호출 비용이 들며, 실행 시점에 따라 성능이 달라질 수 있음을 언급하며, Bud ContextCompact 2.0이 이러한 문제를 해결하고 에이전트의 성공률을 높이는 방법을 경험적으로 검증하고자 한다.

7. 핵심 기여사항:

* SLM 및 제한된 컨텍스트 창 환경에서 에이전트의 컨텍스트 관리를 위한 Bud ContextCompact 2.0 기술 제안.
* 컨텍스트 압축이 SLM의 회상 정확도 및 에이전트의 작업 해결률을 향상시킴을 입증.
* 컨텍스트 압축의 메커니즘, 경계 조건, 비용 효율성에 대한 심층 분석 제공.
* CPU 추론을 포함한 다양한 하드웨어에서 정확도 결과의 전이 가능성을 주장.

8. 실험 결과: 1.2B 파라미터 모델의 회상 정확도를 0.247(잘라내기)에서 0.335로, 9B 모델은 0.515에서 0.577로 향상시켰다. 27B 추론 모델을 사용한 SWE-bench Verified 작업에서 긴 세션의 해결률을 41%에서 53%로 12.3%p 증가시켰다. 해결된 작업당 토큰 사용량은 13% 감소했다. 각 요약에 평균 161초가 소요되어 45분 세션 예산에서는 이득이 사라지는 한계도 보고했다.

9. 내 연구와의 관련성: SLM을 엣지 디바이스에서 에이전트 시스템으로 활용할 때 발생하는 컨텍스트 길이 제약 문제를 해결하는 방법론을 제시한다는 점에서 관련성이 높다. 특히 "tool-using agents"는 function calling/tool calling과 직접적으로 연결되므로, SLM이 제한된 자원 내에서 이러한 기능을 효과적으로 수행하도록 돕는 컨텍스트 관리 전략은 내 연구에 중요한 시사점을 제공한다.

10. 확인해야 할 부분:

* 컨텍스트 압축이 모델의 출력 형식 준수(JSON/schema 등)에 미치는 영향.
* 컨텍스트 압축 과정에서 발생하는 정보 손실이 에이전트의 도구 호출 정확성이나 신뢰성에 미치는 영향.
* 컨텍스트 압축을 위한 요약 모델이 SLM인지, 아니면 별도의 모델인지.
* PEFT/LoRA와 같은 미세 조정 기법이 컨텍스트 압축된 환경에서 에이전트의 성능에 어떻게 기여할 수 있는지.

11. arXiv PDF: https://arxiv.org/pdf/2610.25516.pdf